

本周研究进展汇报

课题组组会

张三

2026 年 6 月 19 日

某某大学 计算机科学与技术学院 某某课题组

指导教师：李四 教授

- 工作一：完成了实验数据采集与预处理，共收集 500 条样本。
- 工作二：实现了基线模型并完成初步训练，准确率达到 85.3%。
- 工作三：阅读了 2 篇相关论文，整理了方法对比笔记。

总体进度

按计划推进，实验部分比预期提前 1 天完成。

- 数据来源：公开数据集 + 自建标注数据（共 500 条）。
- 预处理步骤：
 1. 文本清洗（去除噪声、统一编码为 UTF-8）。
 2. 分词与词性标注（使用 jieba 分词器）。
 3. 构建词表并过滤低频词（频次 < 3 的词语被替换为 $\langle \text{UNK} \rangle$ ）。
- 最终构建了包含 12,000 个词语的词表。

经验记录

jieba 分词在中文科技文本上效果良好，但部分专业术语需要手动添加自定义词典。

实验设置

- 模型：BERT-base-Chinese
- 训练集：400 条
- 验证集：50 条
- 测试集：50 条
- Epochs：10
- Batch size：16

实验结果

- 验证集准确率：**85.3%**
- 测试集准确率：**84.1%**
- 训练耗时：约 12 分钟 (GPU)

遇到的问题与讨论

问题一：模型在小样本类别上效果差

- 现象：测试集中样本数 < 10 的类别，F1 值仅 0.42。
- 已尝试：数据增强（回译、同义词替换）→ 提升不明显。
- 待讨论：是否可以合并低频类别？或引入外部知识图谱？

问题二：训练时间超出预期

- 现象：全量数据训练一次约需 45 分钟（CPU），GPU 资源紧张。
- 已尝试：减小 batch size → 收敛变慢。
- 待讨论：是否可以使用混合精度训练？或有其他 GPU 资源可用？

下周工作计划

1. 模型改进（预计 3 天）

- 调研注意力机制变体方案。
- 实现 2 种改进模型并对比效果。

2. 实验补充（预计 2 天）

- 补充消融实验（验证各模块的贡献）。
- 整理实验数据表格和图表。

3. 论文撰写（预计 2 天）

- 更新 Related Work 部分（新增 2 篇引用）。
- 完成实验分析部分的初稿。

目标

下周末前完成改进模型的初步实验，并提交实验分析草稿给导师审阅。

谢谢！

请各位老师和同学批评指正